

1. Regressão Logística

No primeiro passo, iremos testar um algoritmo simples de regressão logística para responder a primeira pergunta:

Quanto conseguimos detectar usando um modelo relativamente simples e interpretável?

Pontos fortes

- treinamento rápido;
- inferência rápida;
- produz scores;
- fácil de explicar;
- coeficientes podem ser analisados;
- aceita pesos para compensar o desbalanceamento;
- funciona bem como referência para comparar modelos mais complexos.

Limitações

A Regressão Logística aprende principalmente relações lineares.

Ela pode ter dificuldade para aprender relações como:

Uma compra de determinado valor só é suspeita quando acontece durante a madrugada, em uma categoria específica e muito distante da localização do cliente.

Essa combinação envolve interações que modelos baseados em árvores conseguem aprender mais naturalmente.

O que é a regressão logística?

Diferente da regressão linear, que prevê valores contínuos, a regressão logística estima a probabilidade de um determinado evento ocorrer. Por exemplo, podemos usar a regressão logística para prever se um e-mail é spam ou não, se um cliente fará uma compra ou não, entre outros casos.

4 RESULTADOS E DISCUSSÃO

4.1 Regressão Logística como modelo de referência

A Regressão Logística foi o primeiro algoritmo de aprendizado de máquina avaliado neste estudo. Sua utilização teve como objetivo estabelecer um **modelo de referência**, também denominado *baseline*, para as comparações posteriores com algoritmos mais complexos. Uma baseline não precisa representar a solução definitiva do problema. Sua função é fornecer um ponto inicial reproduzível, relativamente simples e interpretável, permitindo verificar se modelos como Random Forest, XGBoost ou CatBoost produzem ganhos efetivos de desempenho.

Embora possua o termo “regressão” em sua denominação, a Regressão Logística pode ser utilizada em problemas de **classificação binária**, isto é, situações nas quais existem duas classes possíveis. Neste trabalho, as classes consideradas foram:

- classe 0: transação legítima;
- classe 1: transação fraudulenta.

O modelo recebe as características de cada transação e calcula um **score** entre 0 e 1. Quanto maior o score, maior a evidência aprendida pelo modelo de que a observação pertence à classe de fraude. Esse valor não deve ser automaticamente interpretado como uma probabilidade perfeitamente calibrada. Para que um score de 0,37 pudesse ser entendido literalmente como 37% de probabilidade de fraude, seria necessária uma análise específica de calibração, que não foi realizada nesta etapa.

Segundo Hosmer, Lemeshow e Sturdivant (2013), a Regressão Logística modela a relação entre um conjunto de variáveis explicativas e a probabilidade de ocorrência de um resultado binário. De forma simplificada, o modelo calcula inicialmente uma combinação linear das variáveis:

$$z = \beta_0 + \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p$$

em que

$$(x_1, x_2, \dots, x_p)$$

representam as características da transação e

$$(\beta_0, \beta_1, \dots, \beta_p)$$

representam os coeficientes aprendidos. Em seguida, a função logística transforma esse valor em um score limitado ao intervalo entre 0 e 1:

$$P(Y = 1 \mid X) = \frac{1}{1 + e^{-z}}$$

Em termos intuitivos, cada coeficiente indica como determinada característica altera a tendência do modelo de atribuir um score maior ou menor à transação, mantendo as demais variáveis constantes. Coeficientes positivos aumentam o score associado à fraude, enquanto

coeficientes negativos o reduzem. Essa interpretação deve ser realizada com cautela, pois associação estatística não implica causalidade.

4.2 Desbalanceamento das classes

A detecção de fraudes é um problema marcado por **forte desbalanceamento de classes**, pois as transações legítimas são muito mais frequentes do que as fraudulentas. No conjunto de validação utilizado nesta etapa, foram observadas 194.501 transações, das quais 1.252 eram fraudulentas e 193.249 eram legítimas. Assim, as fraudes representavam aproximadamente 0,64% das observações.

Esse cenário exige cuidado na escolha das métricas. Um classificador que previsse todas as transações como legítimas atingiria aproximadamente 99,36% de acurácia, apesar de não identificar nenhuma fraude. Portanto, a acurácia isolada não é suficiente para avaliar a qualidade do modelo.

Também foram comparadas duas formas de treinamento:

- `class_weight="balanced"` : atribui maior peso aos erros cometidos na classe minoritária;
- `class_weight=None` : não aplica ponderação adicional entre as classes.

A ponderação balanceada elevou o Recall no threshold padrão, mas gerou grande quantidade de falsos positivos e reduziu fortemente a qualidade geral do ranking. A configuração sem pesos apresentou resultados superiores em Average Precision e ROC-AUC e, por esse motivo, foi selecionada como baseline da Regressão Logística.

Tabela 1 – Comparação das configurações com e sem ponderação das classes

Configuração	Threshold	Average Precision	ROC-AUC	Precision da fraude	Recall da fraude	F1 c frau
<code>class_weight="balanced"</code>	0,50	0,0372	0,8173	2,26%	60,22%	4,36
<code>class_weight=None</code>	0,37	0,4017	0,8906	67,18%	10,46%	18,11

Fonte: elaborado pelo autor (2026).

A configuração balanceada encontrou uma parcela maior das fraudes, porém classificou 32.576 transações legítimas como suspeitas e encaminhou 17,14% de toda a validação para alerta. Em contraste, a configuração sem pesos produziu somente 195 alertas, dos quais 131 eram fraudes. Dessa forma, a escolha da configuração sem pesos não significa que ela tenha encontrado mais fraudes no threshold analisado, mas sim que apresentou uma ordenação de risco muito mais eficiente e uma fila de alertas consideravelmente mais precisa.

4.3 Configuração adotada

A configuração selecionada para representar a baseline foi apresentada no Quadro 1.

Quadro 1 – Configuração da Regressão Logística selecionada como baseline

Parâmetro	Valor	Função no treinamento
<code>class_weight</code>	None	Não adiciona pesos diferentes para as classes. O modelo aprende a partir da distribuição observada nos dados.
<code>penalty</code>	None	Não aplica regularização aos coeficientes.
<code>C</code>	1.0	Parâmetro relacionado à força da regularização. Como <code>penalty=None</code> , não possui efeito prático nesta configuração.
<code>solver</code>	saga	Algoritmo numérico utilizado para estimar os coeficientes da Regressão Logística.
<code>max_iter</code>	500	Número máximo de iterações permitido para o processo de otimização.
<code>threshold</code>	0,37	Ponto de corte utilizado para transformar o score em uma decisão binária.

Fonte: elaborado pelo autor (2026).

O parâmetro `solver="saga"` define o método numérico utilizado para encontrar os coeficientes que minimizam o erro do modelo. Já `max_iter=500` determina apenas o limite máximo de iterações; isso não significa que o algoritmo obrigatoriamente execute todas elas. É recomendável registrar que o treinamento foi concluído sem aviso de não convergência.

Uma observação metodológica importante refere-se ao parâmetro `C`. Na Regressão Logística do *scikit-learn*, `C` representa o inverso da força da regularização. Contudo, como a configuração utilizou `penalty=None`, nenhuma regularização foi aplicada. Consequentemente, o valor `C=1.0` foi armazenado no experimento, mas não explica o desempenho obtido e não deve ser descrito como um parâmetro efetivamente otimizado nesta execução.

O **threshold** não altera o treinamento nem os coeficientes do modelo. Ele atua somente na conversão do score em classe prevista:

$$\hat{Y} = \begin{cases} 1, & \text{se o score} \geq 0,37 \\ 0, & \text{se o score} < 0,37 \end{cases}$$

Assim, reduzir o threshold tende a aumentar o número de transações classificadas como fraude, elevando o Recall e também a quantidade de falsos positivos. Aumentar o threshold produz o efeito inverso: o modelo se torna mais seletivo, normalmente aumentando a Precision, mas deixando mais fraudes sem detecção.

4.4 Métricas de avaliação

Como a base é desbalanceada, a avaliação foi realizada por meio de diferentes métricas, cada uma representando uma dimensão específica do desempenho.

4.4.1 Matriz de confusão

A matriz de confusão organiza as previsões do modelo em quatro resultados possíveis:

- **verdadeiro negativo (TN):** transação legítima corretamente classificada como legítima;
- **falso positivo (FP):** transação legítima incorretamente classificada como fraude;
- **falso negativo (FN):** transação fraudulenta incorretamente classificada como legítima;
- **verdadeiro positivo (TP):** transação fraudulenta corretamente identificada.

No contexto deste trabalho, falsos positivos aumentam a fila de revisão e podem gerar atrito com clientes legítimos. Falsos negativos representam fraudes que não foram identificadas pelo modelo. Portanto, os dois tipos de erro possuem impactos distintos e precisam ser considerados em conjunto.

4.4.2 Acurácia

A acurácia representa a proporção total de previsões corretas:

$$\text{Acurácia} = \frac{TP + TN}{TP + TN + FP + FN}$$

Apesar de intuitiva, essa métrica pode ser enganosa em bases desbalanceadas. Como quase todas as transações são legítimas, um modelo pode apresentar acurácia elevada apenas por favorecer a classe majoritária.

4.4.3 Acurácia balanceada

A acurácia balanceada calcula a média entre a taxa de acerto da classe positiva e a taxa de acerto da classe negativa:

$$\text{Acurácia balanceada} = \frac{\text{Recall da fraude} + \text{Especificidade}}{2}$$

Essa métrica reduz a influência da classe majoritária e atribui importância equivalente às duas classes.

4.4.4 Precision

A Precision da fraude responde à pergunta: **entre todas as transações que o modelo alertou, quantas eram realmente fraudulentas?**

$$\text{Precision} = \frac{TP}{TP + FP}$$

Uma Precision elevada indica que a fila gerada pelo modelo contém poucos alertas indevidos.

4.4.5 Recall

O Recall da fraude responde à pergunta: **entre todas as fraudes existentes, quantas foram encontradas pelo modelo?**

$$\text{Recall} = \frac{TP}{TP + FN}$$

Em detecção de fraude, um Recall baixo significa que muitas ocorrências fraudulentas continuam sendo classificadas como legítimas.

4.4.6 F1-score

O F1-score combina Precision e Recall por meio de uma média harmônica:

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

A média harmônica penaliza situações em que uma métrica é alta e a outra é muito baixa. Por isso, o F1-score é útil para resumir o equilíbrio entre a qualidade dos alertas e a cobertura das fraudes.

4.4.7 ROC-AUC

A curva ROC relaciona a taxa de verdadeiros positivos com a taxa de falsos positivos para diferentes thresholds. A área sob essa curva, denominada ROC-AUC, mede a capacidade geral de ordenação do classificador (FAWCETT, 2006).

Uma interpretação intuitiva da ROC-AUC é a probabilidade de o modelo atribuir um score maior a uma fraude escolhida aleatoriamente do que a uma transação legítima escolhida aleatoriamente. Valores próximos de 0,5 indicam comportamento semelhante ao acaso, enquanto valores próximos de 1 indicam melhor separação entre as classes.

4.4.8 Average Precision

A Average Precision (AP) resume o comportamento da relação entre Precision e Recall ao longo dos thresholds. Ela não corresponde à Precision observada em um único ponto de corte e não deve ser interpretada como “percentual de fraudes detectadas”. A métrica atribui maior valor a modelos que mantêm boa Precision enquanto recuperam uma parcela crescente das fraudes.

Em bases fortemente desbalanceadas, a curva Precision-Recall e a Average Precision costumam ser mais informativas do que a ROC isoladamente, pois concentram a avaliação na classe positiva e nos alertas produzidos (SAITO; REHMSMEIER, 2015).

4.4.9 Percentual alertado

O percentual alertado representa a parcela da base que seria encaminhada para investigação:

$$\text{Percentual alertado} = \frac{TP + FP}{N} \times 100$$

Essa medida aproxima o impacto operacional do modelo. Um classificador pode alcançar alto Recall apenas enviando uma quantidade inviável de transações para revisão. Portanto, a capacidade da equipe de análise deve ser considerada na definição futura dos thresholds.

4.5 Resultados da configuração selecionada

Os resultados obtidos no conjunto de validação são apresentados na Tabela 2.

Tabela 2 – Desempenho da Regressão Logística no conjunto de validação


Métrica	Resultado
Threshold	0,37
Average Precision	0,4017
ROC-AUC	0,8906
Acurácia	99,39%
Acurácia balanceada	55,22%
Precision da fraude	67,18%
Recall da fraude	10,46%
F1-score da fraude	18,11%
Verdadeiros negativos	193.185
Falsos positivos	64
Falsos negativos	1.121
Verdadeiros positivos	131
Percentual alertado	0,10%

Fonte: elaborado pelo autor (2026).

4.5.1 Análise da matriz de confusão

A Figura 1 apresenta a matriz de confusão do modelo. Entre as 193.249 transações legítimas, 193.185 foram corretamente classificadas e apenas 64 foram sinalizadas indevidamente como fraude. Entre as 1.252 fraudes existentes, 131 foram detectadas e 1.121 foram classificadas como legítimas.

Figura 1 – Matriz de confusão da Regressão Logística com threshold de 0,37



Fonte: elaborado pelo autor (2026).

A matriz evidencia um comportamento bastante seletivo. O modelo gerou 195 alertas, dos quais 131 eram fraudes e 64 eram transações legítimas. Isso resultou em Precision de 67,18%, indicando que aproximadamente dois de cada três alertas correspondiam a fraudes reais.

Por outro lado, o Recall foi de apenas 10,46%. Em termos simples, o modelo encontrou aproximadamente uma em cada dez fraudes e deixou passar cerca de nove em cada dez. A taxa de falsos negativos foi, portanto, de aproximadamente 89,54%.


A elevada quantidade de verdadeiros negativos não deve ser interpretada como evidência suficiente de excelente desempenho. A acurácia do modelo foi de 99,39%, enquanto uma estratégia ingênua que classificasse todas as transações como legítimas atingiria cerca de 99,36%. O ganho de acurácia foi de somente 0,03 ponto percentual. Esse resultado reforça que a acurácia não deve ser utilizada isoladamente neste problema.

Em contrapartida, o percentual alertado de 0,10% demonstra uma carga operacional reduzida. A configuração analisada pode ser útil para formar uma fila pequena de casos de alta confiança, mas não seria suficiente, isoladamente, para uma política que pretenda recuperar grande parte das fraudes.

4.5.2 Análise da curva ROC

A Figura 2 apresenta a curva ROC. A linha diagonal representa um classificador aleatório, enquanto a curva do modelo permanece acima dessa referência na maior parte do gráfico.

Figura 2 – Curva ROC da Regressão Logística



Fonte: elaborado pelo autor (2026).


A ROC-AUC obtida foi de 0,8906, indicando boa capacidade de ordenar transações fraudulentas acima das legítimas. Em uma interpretação intuitiva, há aproximadamente 89,06% de chance de uma fraude escolhida aleatoriamente receber score superior ao de uma transação legítima escolhida aleatoriamente.

Entretanto, a ROC-AUC avalia todos os thresholds possíveis e pode transmitir uma visão excessivamente otimista quando a classe negativa é muito numerosa. Por esse motivo, ela foi analisada em conjunto com a Average Precision, a Precision, o Recall e o volume de alertas.

4.5.3 Relação entre Precision, Recall e threshold

A Figura 3 mostra como Precision e Recall variam conforme o threshold. Esse gráfico não é a curva Precision-Recall tradicional: nele, as duas métricas são apresentadas separadamente em função do ponto de corte.

Figura 3 – Precision e Recall em função do threshold



Fonte: elaborado pelo autor (2026).

Thresholds baixos fazem com que mais transações sejam classificadas como fraude. Nessa região, o Recall tende a aumentar porque o modelo identifica uma parcela maior das fraudes, porém a Precision pode diminuir em razão do crescimento dos falsos positivos. Thresholds altos tornam a decisão mais restritiva, reduzindo a quantidade de alertas e, em geral, aumentando a qualidade da fila, mas também elevando o número de fraudes não detectadas.

O threshold de 0,37 adotado nesta baseline privilegiou uma fila pequena e precisa, em detrimento da cobertura. Essa escolha foi utilizada apenas para analisar um cenário inicial de decisão. O ponto de corte operacional definitivo deverá ser selecionado depois da comparação entre todos os algoritmos, considerando custos de falsos positivos, perdas associadas aos falsos negativos e capacidade de revisão manual.


A Average Precision de 0,4017 reforça que o modelo possui capacidade relevante de ranking. Como a prevalência de fraude no conjunto de validação foi de aproximadamente 0,0064, um ranking aleatório teria uma AP próxima a esse valor. O resultado alcançado foi aproximadamente 62 vezes superior à prevalência da classe positiva. Isso não significa que o modelo detectou 40,17% das fraudes; significa que, considerando diversos thresholds, ele conseguiu concentrar fraudes nas posições superiores do ranking com qualidade substancialmente superior ao acaso.

Para representar visualmente a Average Precision de forma mais direta, recomenda-se adicionar posteriormente uma **curva Precision-Recall**, com Recall no eixo horizontal e Precision no eixo vertical. Essa figura é diferente do gráfico por threshold apresentado na Figura 3.

4.5.4 Distribuição dos scores

A Figura 4 apresenta a distribuição dos scores para transações legítimas e fraudulentas. A escala logarítmica no eixo vertical facilita a visualização das regiões com menor densidade de observações.

Figura 4 – Distribuição dos scores da Regressão Logística por classe



Fonte: elaborado pelo autor (2026).


Observa-se que a maior concentração de transações legítimas ocorre em scores próximos de zero. As fraudes apresentam distribuição mais espalhada e maior presença em faixas intermediárias e elevadas. Esse padrão explica a boa ROC-AUC e a Average Precision: o modelo consegue atribuir scores relativamente maiores a muitas fraudes.

Entretanto, existe sobreposição entre as classes. Algumas fraudes recebem scores baixos, enquanto algumas transações legítimas recebem scores elevados. Essa sobreposição impede uma separação perfeita e produz o conflito observado entre Precision e Recall. O threshold de 0,37 seleciona apenas uma fração mais extrema da distribuição, resultando em poucos alertas e baixo Recall.

4.5.5 Interpretação dos coeficientes

A Regressão Logística permite inspecionar os coeficientes associados às variáveis, oferecendo maior transparência do que muitos modelos não lineares. A Figura 5 apresenta os coeficientes de maior magnitude.

Figura 5 – Coeficientes de maior magnitude na Regressão Logística



Fonte: elaborado pelo autor (2026).

Coeficientes positivos estão associados ao aumento do logaritmo das chances de fraude, enquanto coeficientes negativos estão associados à sua redução. No modelo ajustado, a variável associada ao estado DE apresentou o maior coeficiente positivo, seguida por `amt_log`, `state_RI` e `hora_cos`. Entre os coeficientes negativos de maior magnitude aparecem variáveis associadas a gênero, categoria de viagem e determinados estados.

A variável `amt_log` representa o valor da transação após transformação logarítmica. Seu coeficiente positivo sugere que, mantidas as demais variáveis constantes, aumentos no valor transformado estão associados a scores maiores de fraude. Já `hora_cos` faz parte de uma codificação cíclica do horário e não deve ser interpretada isoladamente; sua leitura adequada depende também da variável `hora_sin`.

Os coeficientes de estados e categorias devem ser interpretados em relação à codificação utilizada no pré-processamento. Caso todas as variáveis *dummy* tenham sido mantidas, sem a remoção de uma categoria de referência, a interpretação individual torna-se menos direta. Além disso, o coeficiente elevado de `state_DE` pode estar relacionado à frequência da

categoria, à concentração de fraudes naquele grupo ou a um fenômeno de separação estatística. Antes de atribuir significado substantivo, deve-se verificar o número de observações e a taxa de fraude por estado.

Outro ponto de cautela é a ausência de regularização (`penalty=None`). Sem uma penalização sobre coeficientes muito elevados, categorias raras ou padrões específicos da amostra podem produzir valores extremos e instáveis. Por esse motivo, o gráfico deve ser apresentado como uma análise exploratória de interpretabilidade, e não como evidência causal de que determinada característica provoca fraude.

4.6 Síntese dos resultados

A Regressão Logística sem ponderação das classes apresentou Average Precision de 0,4017 e ROC-AUC de 0,8906, resultados substancialmente superiores aos obtidos com `class_weight="balanced"` . A configuração selecionada demonstrou boa capacidade de ordenar as transações conforme o risco, produzindo alertas com Precision de 67,18%.

Entretanto, o threshold de 0,37 resultou em Recall de apenas 10,46%, indicando que a política de decisão foi excessivamente restritiva para uma solução destinada a detectar a maior parcela possível das fraudes. Em contrapartida, somente 0,10% das transações foram alertadas, o que representa uma fila operacional pequena e de alta qualidade.

Dessa forma, a principal conclusão não é que a Regressão Logística tenha solucionado o problema, mas que ela cumpriu adequadamente sua função como baseline. O modelo aprendeu um sinal relevante, apresentou boa capacidade de ranking e forneceu uma referência objetiva para os algoritmos seguintes. A seleção definitiva do threshold não foi encerrada nesta etapa, pois deverá considerar o desempenho dos demais modelos e os objetivos operacionais do sistema.

A configuração foi, portanto, congelada como baseline com `class_weight=None` , `penalty=None` , `solver="saga"` , `max_iter=500` e threshold preliminar de 0,37. Os modelos posteriores deverão utilizar a mesma divisão temporal, o mesmo conjunto de validação e as mesmas métricas, permitindo uma comparação metodologicamente consistente.

4.7 Limitações desta etapa

Os resultados apresentados possuem as seguintes limitações:

1. as métricas foram calculadas no conjunto de validação e não representam ainda a avaliação final no conjunto de teste;
2. o threshold de 0,37 é preliminar e não foi definido a partir de custos financeiros ou capacidade real de revisão;
3. a calibração dos scores não foi avaliada;

4. a ausência de regularização pode produzir coeficientes instáveis, principalmente em categorias raras;
5. a interpretação dos coeficientes representa associação estatística, não causalidade;
6. os resultados estão condicionados às variáveis construídas, ao período analisado e às características da base utilizada;
7. por se tratar de uma baseline, não foi realizada uma busca extensa de hiperparâmetros.

O conjunto de teste deverá permanecer intocado durante o desenvolvimento. Após a comparação e seleção do algoritmo final, ele deverá ser utilizado uma única vez para estimar o desempenho fora da amostra de validação.

REFERÊNCIAS

FAWCETT, Tom. An introduction to ROC analysis. *Pattern Recognition Letters*, v. 27, n. 8, p. 861-874, 2006. DOI: 10.1016/j.patrec.2005.10.010.

HOSMER, David W.; LEMESHOW, Stanley; STURDIVANT, Rodney X. *Applied logistic regression*. 3. ed. Hoboken: John Wiley & Sons, 2013. DOI: 10.1002/9781118548387.

JAMES, Gareth; WITTEN, Daniela; HASTIE, Trevor; TIBSHIRANI, Robert; TAYLOR, Jonathan. *An introduction to statistical learning: with applications in Python*. Cham: Springer, 2023. DOI: 10.1007/978-3-031-38747-0.

PEDREGOSA, Fabian et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.

SAITO, Takaya; REHMSMEIER, Marc. The Precision-Recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, v. 10, n. 3, e0118432, 2015. DOI: 10.1371/journal.pone.0118432.