

2. Random Forest

2. Random Forest

No segundo passo, foi testado o algoritmo **Random Forest** para responder à seguinte pergunta:

Quanto o desempenho pode melhorar quando saímos de um modelo linear e interpretável, como a Regressão Logística, para um modelo baseado em árvores, capaz de aprender interações e padrões não lineares?

Pontos fortes

- aprende relações não lineares de forma natural;
- capta interações entre variáveis sem exigir especificação manual;
- costuma apresentar bom desempenho preditivo em problemas tabulares;
- produz scores que podem ser convertidos em decisões operacionais por meio de threshold;
- é robusto a outliers e a diferentes escalas das variáveis numéricas;
- fornece medidas de importância das variáveis.

Limitações

- possui menor interpretabilidade direta do que a Regressão Logística;
- a importância das variáveis não deve ser confundida com causalidade;
- pode favorecer variáveis contínuas nas importâncias baseadas em impureza;
- exige maior custo computacional de treinamento;
- sem ajuste de threshold, pode não refletir a política operacional desejada.

O que é a Random Forest?

A Random Forest é um algoritmo de aprendizado supervisionado baseado em **conjunto de árvores de decisão**. Em vez de construir uma única árvore, o método treina diversas árvores sobre amostras ligeiramente diferentes da base de treinamento e combina suas previsões. Em problemas de classificação, a previsão final pode ser entendida como um voto combinado das árvores ou, de forma mais útil neste trabalho, como um **score de fraude** obtido a partir da proporção de árvores que classificaram a transação como fraudulenta.

De forma intuitiva, cada árvore aprende regras do tipo:

- se a compra ocorreu em determinada categoria;
- e se o valor da transação é elevado;
- e se o horário está em uma faixa específica;
- e se a distância em relação ao local esperado do cliente é alta;

então a transação tende a apresentar maior risco de fraude.

A combinação de várias árvores reduz a instabilidade que seria observada em uma única árvore isolada. Além disso, a Random Forest introduz aleatoriedade de duas formas principais:

1. cada árvore é treinada em uma **amostra bootstrap** da base de treino;
2. em cada divisão da árvore, apenas um subconjunto aleatório das variáveis é avaliado.

Essa estratégia aumenta a diversidade entre as árvores e tende a melhorar a generalização do modelo.

4 RESULTADOS E DISCUSSÃO

4.8 Random Forest como modelo baseado em árvores

Após a construção da Regressão Logística como baseline, foi implementada a Random Forest com o objetivo de verificar se um modelo não linear, capaz de capturar interações entre variáveis, produziria ganhos efetivos no problema de detecção de fraudes em cartões de crédito.

A principal motivação para o uso desse algoritmo é que fraudes podem emergir de **combinações específicas de atributos**. Por exemplo, uma compra pode se tornar suspeita não apenas por seu valor, mas pela combinação entre valor, horário, categoria, localização e perfil do cliente. Enquanto a Regressão Logística modela a relação entre variáveis e score de forma essencialmente linear, a Random Forest aprende essas interações de forma mais natural.

Neste estudo, foram mantidos os mesmos conjuntos de treino, validação e teste utilizados na baseline, bem como o mesmo conjunto de variáveis derivadas, a fim de preservar a comparabilidade metodológica entre os algoritmos.

4.8.1 Desbalanceamento das classes

O problema continua fortemente desbalanceado. No conjunto de validação foram observadas **194.501 transações**, das quais **1.252 eram fraudulentas** e **193.249 eram legítimas**. Assim, a prevalência da classe positiva foi de aproximadamente **0,64%**.

Esse cenário reforça a necessidade de avaliar o modelo com métricas mais informativas do que a acurácia isolada. Embora a Random Forest tenha apresentado acurácia elevada, essa

métrica não deve ser interpretada sozinha. As análises principais desta etapa concentraram-se em:

- Average Precision (AP);
- ROC-AUC;
- Precision da fraude;
- Recall da fraude;
- F1-score;
- matriz de confusão;
- percentual alertado.

4.8.2 Configurações avaliadas

Diferentemente da Regressão Logística, a Random Forest exige a definição de hiperparâmetros diretamente relacionados à complexidade das árvores e à composição da floresta. Nesta etapa, foram comparadas três configurações principais.

Tabela 1 – Comparação entre as configurações avaliadas da Random Forest no conjunto de validação

Configuração	max_depth	min_samples_split	min_samples_leaf	Average Precision	ROC AUC
Random Forest inicial	20	10	5	0,8773	0,9917
Random Forest intermediária	30	4	2	0,8985	0,9927
Random Forest final	40	4	2	0,9006	0,9919

Fonte: elaborado pelo autor (2026).

A primeira configuração já superou amplamente a baseline de Regressão Logística. Em seguida, foram realizados ajustes controlados com o objetivo de aumentar a capacidade das árvores de representar padrões mais específicos de fraude. A passagem de `max_depth=20` , `min_samples_split=10` e `min_samples_leaf=5` para uma configuração mais flexível (`max_depth=30` , `min_samples_split=4` , `min_samples_leaf=2`) produziu um salto importante em Recall e F1-score. Por fim, o aumento da profundidade máxima para 40 gerou uma melhora incremental, porém consistente, levando à configuração final selecionada.

4.8.3 Configuração adotada

A configuração selecionada para representar a melhor Random Forest desta etapa foi apresentada no Quadro 1.

Quadro 1 – Configuração da Random Forest selecionada

Parâmetro	Valor	Função no treinamento
n_estimators	200	Quantidade de árvores construídas na floresta.
criterion	gini	Critério de impureza utilizado para escolher as divisões em cada árvore.
max_depth	40	Profundidade máxima permitida para cada árvore. Controla a complexidade do modelo.
min_samples_split	4	Número mínimo de observações necessário para dividir um nó interno.
min_samples_leaf	2	Número mínimo de observações que deve existir em cada folha terminal.
max_features	sqrt	Quantidade de variáveis candidatas a cada divisão, definida como a raiz quadrada do total de atributos.
bootstrap	True	Indica que cada árvore foi treinada em uma amostra com reposição da base de treino.
class_weight	None	Não adiciona pesos extras para a classe fraudulenta nesta etapa.
threshold	0,50	Ponto de corte usado para converter o score do modelo em classe prevista.

Fonte: elaborado pelo autor (2026).

O parâmetro `n_estimators=200` define o tamanho da floresta. Em termos intuitivos, quanto maior esse valor, maior tende a ser a estabilidade do ensemble, embora o custo computacional também aumente. O parâmetro `max_depth=40` permite árvores profundas o suficiente para capturar interações complexas, sem recorrer a um crescimento completamente irrestrito.

Os parâmetros `min_samples_split=4` e `min_samples_leaf=2` foram importantes para permitir folhas menores e, conseqüentemente, regras mais específicas. Isso é especialmente relevante em um problema de fraude, no qual padrões raros podem carregar forte sinal preditivo. Já `max_features="sqrt"` aumenta a diversidade entre as árvores, uma vez que cada divisão passa a considerar apenas parte das variáveis disponíveis.

Assim como na Regressão Logística, o **threshold** não altera o treinamento do modelo. Ele atua somente na transformação do score em classe prevista:

$$\hat{Y} = \begin{cases} 1, & \text{se o score} \geq 0,50 \\ 0, & \text{se o score} < 0,50 \end{cases}$$

Reduzir o threshold tende a elevar o Recall, porque mais transações são encaminhadas para alerta. Em contrapartida, também tende a aumentar a quantidade de falsos positivos. O ajuste do ponto de corte operacional definitivo deverá ser realizado posteriormente, de forma comparativa entre os algoritmos.

4.8.4 Métricas de avaliação

As métricas empregadas nesta etapa foram as mesmas utilizadas na Regressão Logística, de forma a garantir comparabilidade metodológica. Como o problema é desbalanceado, nenhuma métrica isolada é suficiente para resumir o desempenho.

4.8.4.1 Matriz de confusão

A matriz de confusão organiza as previsões do modelo em quatro categorias:

- verdadeiro negativo (TN): transação legítima corretamente classificada como legítima;
- falso positivo (FP): transação legítima incorretamente classificada como fraude;
- falso negativo (FN): transação fraudulenta incorretamente classificada como legítima;
- verdadeiro positivo (TP): transação fraudulenta corretamente identificada.

4.8.4.2 Acurácia

A acurácia representa a proporção total de previsões corretas. Em bases desbalanceadas, no entanto, ela pode ser artificialmente elevada em razão do grande volume de transações legítimas.

4.8.4.3 Acurácia balanceada

A acurácia balanceada corresponde à média entre a sensibilidade da classe positiva e a especificidade da classe negativa. Essa métrica reduz o peso excessivo da classe majoritária.

4.8.4.4 Precision

A Precision da fraude responde à pergunta: **entre todas as transações que o modelo alertou, quantas eram realmente fraudulentas?**

4.8.4.5 Recall

O Recall da fraude responde à pergunta: **entre todas as fraudes existentes, quantas foram encontradas pelo modelo?**

4.8.4.6 F1-score

O F1-score resume o equilíbrio entre Precision e Recall. Ele é especialmente útil quando se deseja avaliar simultaneamente a qualidade da fila de alertas e a cobertura das fraudes.

4.8.4.7 ROC-AUC

A ROC-AUC mede a capacidade geral de ordenação do classificador. Em termos intuitivos, pode ser interpretada como a probabilidade de uma fraude escolhida aleatoriamente receber score superior ao de uma transação legítima escolhida aleatoriamente.

4.8.4.8 Average Precision

A Average Precision (AP) resume o comportamento conjunto de Precision e Recall ao longo de diferentes thresholds. Em bases desbalanceadas, essa métrica costuma ser mais informativa do que a ROC-AUC isoladamente.

4.8.4.9 Percentual alertado

O percentual alertado representa a fração da base que seria encaminhada para investigação. Trata-se de uma métrica importante do ponto de vista operacional, pois um classificador só é útil se a fila gerada puder ser absorvida pelo processo de revisão.

4.8.5 Resultados da configuração selecionada

Os resultados obtidos no conjunto de validação para a configuração final da Random Forest são apresentados na Tabela 2.

Tabela 2 – Desempenho da Random Forest no conjunto de validação

Métrica	Resultado
Threshold	0,50
Average Precision	0,9006
ROC-AUC	0,9919
Acurácia	99,80%
Acurácia balanceada	84,78%
Precision da fraude	98,31%
Recall da fraude	69,57%


Métrica	Resultado
F1-score da fraude	81,48%
Verdadeiros negativos	193.234
Falsos positivos	15
Falsos negativos	381
Verdadeiros positivos	871
Percentual alertado	0,46%

Fonte: elaborado pelo autor (2026).

4.8.5.1 Análise da matriz de confusão

A Figura 1 apresenta a matriz de confusão do modelo. Entre as **193.249 transações legítimas**, **193.234** foram corretamente classificadas e apenas **15** foram sinalizadas indevidamente como fraude. Entre as **1.252 fraudes existentes**, **871** foram detectadas e **381** foram classificadas como legítimas.

Figura 1 – Matriz de confusão da Random Forest com threshold de 0,50



Fonte: elaborado pelo autor (2026).


A matriz evidencia um comportamento muito mais forte do que o observado na Regressão Logística. O modelo gerou **886 alertas**, dos quais **871 eram realmente fraudes** e apenas **15** eram transações legítimas. Isso resultou em **Precision de 98,31%**, indicando uma fila de alertas extremamente precisa.

Além disso, o **Recall de 69,57%** mostra que o modelo recuperou aproximadamente sete em cada dez fraudes presentes no conjunto de validação. Apesar de ainda existirem **381 falsos negativos**, o resultado representa uma cobertura substancialmente superior à baseline linear.

4.8.5.2 Análise da curva ROC

A Figura 2 apresenta a curva ROC. A curva do modelo permanece muito próxima do canto superior esquerdo do gráfico, enquanto a linha diagonal representa o comportamento de um classificador aleatório.

Figura 2 – Curva ROC da Random Forest



Fonte: elaborado pelo autor (2026).


A **ROC-AUC de 0,9919** indica capacidade extremamente alta de separação entre as classes. Em uma interpretação intuitiva, há aproximadamente **99,19% de chance** de uma fraude sorteada aleatoriamente receber score superior ao de uma transação legítima sorteada aleatoriamente.

Entretanto, como a classe negativa é muito numerosa, a ROC-AUC não deve ser interpretada isoladamente. Por isso, sua leitura foi complementada pela Average Precision e pelas análises baseadas em threshold.

4.8.5.3 Curva Precision-Recall

A Figura 3 apresenta a curva Precision-Recall da Random Forest.

Figura 3 – Curva Precision-Recall da Random Forest



Fonte: elaborado pelo autor (2026).


A **Average Precision de 0,9006** é muito superior à prevalência da classe fraudulenta no conjunto de validação, aproximadamente **0,0064**. Isso significa que o ranking produzido pelo modelo concentra fraudes nas posições superiores com qualidade muito superior ao acaso.

Em outras palavras, a Random Forest não apenas classifica bem em um único threshold, mas também mantém uma relação favorável entre Precision e Recall ao longo de diversos pontos de corte. Em um cenário desbalanceado como este, esse é um dos sinais mais fortes de qualidade do modelo.

4.8.5.4 Relação entre Precision, Recall e threshold

A Figura 4 mostra como Precision e Recall variam em função do threshold.

Figura 4 – Precision e Recall em função do threshold na Random Forest



Fonte: elaborado pelo autor (2026).


Observa-se que thresholds mais baixos aumentam o Recall, pois fazem com que mais transações sejam classificadas como fraude. Contudo, essa estratégia tende a reduzir a Precision, elevando a quantidade de falsos positivos. Thresholds mais altos produzem o efeito oposto: a fila se torna mais seletiva e mais precisa, mas menos abrangente.

O threshold de **0,50**, adotado nesta etapa, posiciona o modelo em uma região bastante favorável: Precision muito alta e Recall já expressivo. Ainda assim, o gráfico mostra que existe espaço para estudos posteriores de ajuste de threshold, caso se deseje privilegiar ainda mais a cobertura das fraudes.

4.8.5.5 Distribuição dos scores

A Figura 5 apresenta a distribuição dos scores para transações legítimas e fraudulentas. A escala logarítmica no eixo vertical facilita a visualização das regiões com baixa densidade.

Figura 5 – Distribuição dos scores da Random Forest por classe



Fonte: elaborado pelo autor (2026).


Observa-se uma forte concentração de transações legítimas em scores próximos de zero, enquanto as fraudes aparecem predominantemente em faixas elevadas do score. Isso ajuda a explicar a excelente ROC-AUC e a alta Average Precision do modelo.

Ainda assim, existe alguma sobreposição entre as classes, o que impede separação perfeita. Essa sobreposição justifica a existência de falsos positivos e falsos negativos, mesmo em um modelo com desempenho elevado.

4.8.5.6 Importância das variáveis

Diferentemente da Regressão Logística, a Random Forest não produz coeficientes lineares diretamente interpretáveis. Em seu lugar, o algoritmo permite estimar a **importância das variáveis**, ou seja, o quanto cada atributo contribuiu para reduzir a impureza nas árvores do ensemble.

Figura 6 – Variáveis com maior importância na Random Forest



Fonte: elaborado pelo autor (2026).

A variável **amt_log** apresentou a maior importância, indicando que o valor da transação, após transformação logarítmica, foi o principal atributo para diferenciar fraudes de transações legítimas. Em seguida aparecem variáveis associadas ao **horário da transação** (**hora_sin** e **hora_cos**), à **idade**, à **categoria da compra** e à **distância**.

Esse resultado sugere que a Random Forest aprendeu um padrão mais rico do que o observado na Regressão Logística, incorporando relações entre valor, tempo, categoria e contexto geográfico. Ainda assim, deve-se enfatizar que **importância não implica causalidade**. Além disso, importâncias baseadas em impureza podem favorecer variáveis numéricas contínuas. Portanto, a figura deve ser interpretada como evidência de relevância preditiva, e não como prova causal.

4.8.6 Comparação com a Regressão Logística baseline

A Tabela 3 resume a comparação entre a baseline de Regressão Logística e a configuração final da Random Forest.

Tabela 3 – Comparação entre Regressão Logística e Random Forest

Modelo	Threshold	Average Precision	ROC-AUC	Precision da fraude	Recall da fraude	F1-score	FP	TF
Regressão Logística	0,37	0,4017	0,8906	67,18%	10,46%	18,11%	64	13
Random Forest	0,50	0,9006	0,9919	98,31%	69,57%	81,48%	15	87

Fonte: elaborado pelo autor (2026).

A comparação mostra que a Random Forest superou amplamente a baseline em praticamente todas as dimensões relevantes. A AP passou de **0,4017 para 0,9006**, indicando um ganho expressivo na capacidade de ranking. A ROC-AUC subiu de **0,8906 para 0,9919**, enquanto o Recall aumentou de **10,46% para 69,57%**.

Do ponto de vista operacional, a Random Forest gerou uma fila um pouco maior, mas ainda bastante enxuta. O percentual alertado passou de **0,10% para 0,46%**, ao mesmo tempo em que o número de fraudes efetivamente detectadas aumentou de **131 para 871**. O total de falsos positivos, por sua vez, caiu de **64 para 15**.

Em síntese, a Random Forest foi capaz de detectar muito mais fraudes, com uma fila mais precisa e com menor volume de alertas indevidos do que a Regressão Logística.

4.8.7 Síntese dos resultados

A Random Forest apresentou desempenho muito superior ao da baseline de Regressão Logística. A configuração final, com `n_estimators=200`, `criterion="gini"`, `max_depth=40`, `min_samples_split=4`, `min_samples_leaf=2`, `max_features="sqrt"`, `bootstrap=True` e `class_weight=None`, obteve **Average Precision de 0,9006** e **ROC-AUC de 0,9919**.

No threshold de 0,50, o modelo produziu **Precision de 98,31%**, **Recall de 69,57%** e **F1-score de 81,48%**, sinalizando uma fila de alertas extremamente precisa e, ao mesmo tempo, uma cobertura expressiva das fraudes. O modelo identificou **871 fraudes** e incorreu em apenas **15 falsos positivos** no conjunto de validação.

A principal conclusão desta etapa é que a Random Forest não apenas superou a baseline, mas estabeleceu um novo patamar de desempenho para o problema estudado. A melhora observada não se restringiu a uma única métrica, tendo ocorrido de forma simultânea na Average Precision, na qualidade da fila, na cobertura das fraudes e na relação entre erros positivos e negativos.

Dessa forma, a Random Forest foi selecionada como **modelo candidato principal** dentre os algoritmos avaliados até o momento. Ainda assim, sua avaliação final dependerá da comparação posterior com modelos de boosting, como XGBoost e CatBoost, bem como de futura validação no conjunto de teste.

4.8.8 Limitações desta etapa

Os resultados apresentados possuem as seguintes limitações:

1. as métricas foram calculadas no conjunto de validação e não representam ainda a avaliação final no conjunto de teste;
2. o threshold de 0,50 é preliminar e ainda poderá ser ajustado conforme os objetivos operacionais do sistema;
3. as importâncias das variáveis representam relevância preditiva e não causalidade;
4. importâncias baseadas em impureza podem favorecer variáveis contínuas, como `amt_log` ;
5. embora tenham sido testadas três configurações, não foi realizada busca exaustiva de hiperparâmetros;
6. os resultados permanecem condicionados às variáveis construídas, ao período analisado e às características específicas da base utilizada.

O conjunto de teste deverá permanecer intocado durante o desenvolvimento. Após a comparação e seleção do algoritmo final, ele deverá ser utilizado uma única vez para estimar o desempenho fora da amostra de validação.

REFERÊNCIAS

BREIMAN, Leo. Random forests. *Machine Learning*, v. 45, p. 5-32, 2001.

FAWCETT, Tom. An introduction to ROC analysis. *Pattern Recognition Letters*, v. 27, n. 8, p. 861-874, 2006. DOI: 10.1016/j.patrec.2005.10.010.

JAMES, Gareth; WITTEN, Daniela; HASTIE, Trevor; TIBSHIRANI, Robert; TAYLOR, Jonathan. *An introduction to statistical learning: with applications in Python*. Cham: Springer, 2023. DOI: 10.1007/978-3-031-38747-0.

PEDREGOSA, Fabian et al. Scikit-learn: machine learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.

SAITO, Takaya; REHMSMEIER, Marc. The Precision-Recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, v. 10, n. 3, e0118432, 2015. DOI: 10.1371/journal.pone.0118432.